phase2a

January 10, 2023

1 Przygotowania - pobieranie danych itp.

```
[1]: pip install googledrivedownloader
    Requirement already satisfied: googledrivedownloader in
    /opt/conda/lib/python3.10/site-packages (0.4)
    Note: you may need to restart the kernel to use updated packages.
[2]: from google_drive_downloader import GoogleDriveDownloader as gdd
     from pathlib import Path
     path_dir = str(Path.home()) + "/data/2020/" # ustawmy sciezke na HOME/data/2020
     archive_dir = path_dir + "survey.zip"
                                              # plik zapiszemy pod nazwa survey.
      \hookrightarrow zip
     gdd.download_file_from_google_drive(
         file_id='1dfGerWeWkcyQ9GX9x20rdSGj7WtEpzBB',
         dest_path=archive_dir,
         unzip=True
     )
     csv_path = 'file:///home/jovyan/data/2020/survey_results_public.csv'
[3]: from pyspark.sql import SparkSession
     sparkSession = SparkSession \
     .builder \
     .config("spark.executor.instances", "1")\
     .config('spark.driver.memory','1g')\
     .config('spark.executor.memory', '1g') \
     .getOrCreate()
     df = sparkSession.read.csv(csv_path, inferSchema=True, header="true",_
      →nullValue='NA', nanValue='NA',emptyValue='NA')
```

2 Punkt 2a)

```
[4]: a result = df.select(df.EdLevel).distinct()
     a_result.show(truncate = False)
     a_result.count()
    ---+
    |EdLevel
    |Primary/elementary school
    null
    |Other doctoral degree (Ph.D., Ed.D., etc.)
    |I never completed any formal education
    |Bachelor's degree (B.A., B.S., B.Eng., etc.)
    |Associate degree (A.A., A.S., etc.)
    |Secondary school (e.g. American high school, German Realschule or Gymnasium,
    etc.)|
    |Professional degree (JD, MD, etc.)
    |Master's degree (M.A., M.S., M.Eng., MBA, etc.)
    |Some college/university study without earning a degree
[4]: 10
    2.0.1 Odpowiedź: 10, ale jedna jest nullem
    3 Punkt 2b)
[5]: from pyspark.sql.functions import *
     b_result = df.groupBy("Country").avg("WorkWeekHrs")
     b_result.show(truncate=False)
```

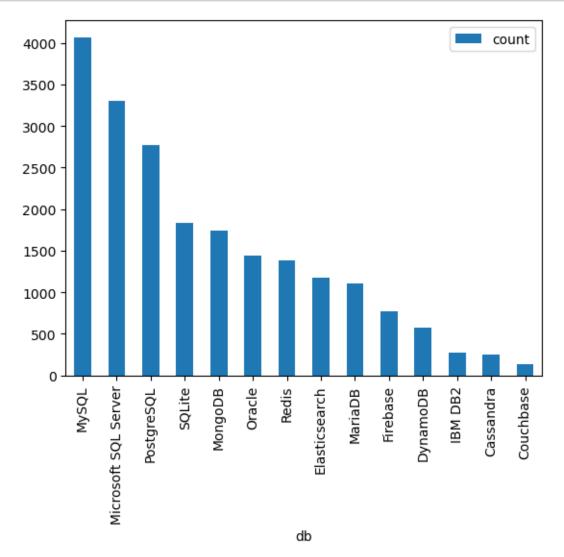
```
Country
                                  |avg(WorkWeekHrs) |
+----+
Senegal
                                  |34.285714285714285|
Sweden
                                  40.7496062992126
|Hong Kong (S.A.R.)
                                  |42.298507462686565|
|Republic of Korea
                                  |35.138888888888886|
|Philippines
                                  |37.32920792079208 |
                                  |40.25684931506849 |
Singapore
|Turkey
                                  |43.77202643171806 |
                                   |49.07142857142857 |
|Iraq
                                  140.27298744460857
Germany
|Afghanistan
                                  146.5
Jordan
                                   45.806451612903224
Sudan
                                   |36.714285714285715|
|France
                                   |40.38484399375975 |
Greece
                                   |41.82364341085271 |
|Sri Lanka
                                  |40.61224489795919 |
|Taiwan
                                  |40.67032967032967 |
|Algeria
                                  136.86206896551724 |
|Slovakia
                                  |43.06153846153846 |
|Venezuela, Bolivarian Republic of...|40.1219512195122 |
Argentina
only showing top 20 rows
```

Aby pokazać wszystkie państwa, można użyć argumentu metody show, na przykład: b_result.show(b_result.count()) pokaże wszystkie 184 wiersze.

4 Punkt 2c)

```
.drop("pos") \
.withColumnRenamed("col", "db")

counted = single_dbs.groupBy("db").count().sort(col("count").desc()).toPandas()
counted.plot.bar(x='db', y="count");
```



5 Punkt 2d)

```
[7]: db_name = 'base'
  table_name = 'survey'

[8]: sparkSession.sql(f'DROP DATABASE IF EXISTS {db_name} CASCADE')
  sparkSession.sql(f'CREATE DATABASE {db_name}')
```

```
[9]: spark_df = sparkSession.sql(f'SELECT *, CAST((convertedComp > 60000) AS STRING)

→AS compAboveAvg \

FROM {table_name} where convertedComp IS NOT NULL ')

y = 'compAboveAvg'
```

5.0.1 Wybrane zostały inne cechy niż w oryginalnym notatniku:

5.0.2 Zbadany został stosunek liczności klas:

```
[11]: major_df = spark_df.filter(col(y) == True)
minor_df = spark_df.filter(col(y) == False)
ratio = major_df.count()/minor_df.count()
print("class ratio: {}".format(ratio))
```

class ratio: 0.8084187522763931

Stosunek wynosi około 4:5, więc klasy są całkiem dobrze zbalansowane.

```
[12]: from pyspark.ml.feature import StringIndexer, OneHotEncoder, VectorAssembler from pyspark.ml import Pipeline
```

5.0.3 Próby użycia selekcji cech nie przyniosły rezultatów, model dawał lepsze wyniki przy ręcznej selekcji większej liczby atrybutów

6 Trenowanie modelu:

6.0.1 Wybrany został model Gradient-Boosted Trees (GBT), użyty został większy parametr maxIter oraz maxDepth

```
[17]: from pyspark.ml.classification import GBTClassifier
      gbt = GBTClassifier(labelCol="label", featuresCol="features", maxIter = 30,
       →maxDepth=8)
      model = gbt.fit(training)
[18]: prediction = model.transform(test)
      label_and_pred = prediction.select('label', 'prediction')
      label_and_pred.groupBy('label', 'prediction').count().toPandas()
[18]:
         label prediction count
           1.0
                       1.0
                             2495
      0
      1
           0.0
                       1.0
                              500
      2
           1.0
                       0.0
                              580
      3
           0.0
                       0.0
                             3376
[19]: from pyspark.ml.evaluation import BinaryClassificationEvaluator
      from pyspark.mllib.evaluation import BinaryClassificationMetrics
      evaluator = BinaryClassificationEvaluator(rawPredictionCol="rawPrediction", __
       →metricName="areaUnderROC")
      evaluator.evaluate(prediction)
```

[19]: 0.9130518848532139

7 Ostateczne wyniki naszego modelu:

7.1 Gradient Boosted Trees z inaczej dobranymi cechami i hiperparametrami

AUC = 0.9131

Jest to wynik lepszy niż każdy z wcześniejszych modeli z notatnika ml.ipynb:

0.6139 (dla DecisionTreeClassifier)

0.6784 (dla DecisionTreeClassifier z walidacją krzyżową)

0.8838 (dla GBT)

Ustawianie większej wartości parametru maxIter powoduje wzrost metryki auROC kosztem dłuższego czasu trenowania.

Dla maxIter > 30 czas trenowania jest już dość długi, a wzrost metryki minimalny.

Parametr maxDepth został ręcznie wybrany na wartość 8, prawdopodobnie przy większych wartościach dochodzi do przeuczenia.

[20]: sparkSession.stop()